

La donnée est l'actif stratégique de la révolution numérique

## Analyse budget et consommation avec Python

- Source des données : ---  
</blocquote>

```
In [1]: import pandas as pd
import numpy as np
import matplotlib.pyplot as plt
import seaborn as sns
```

```
In [2]: # Chargement des données

budget = pd.read_csv("Budget.csv", sep=";")
comptes = pd.read_excel("Comptes.xlsx")
conso2014 = pd.read_csv("Conso2014.csv", sep=";")
conso2015 = pd.read_csv("Conso2015.csv", sep=";")
conso2016 = pd.read_csv("Conso2016.csv", sep=";")
conso2017 = pd.read_csv("Conso2017.csv", sep=";")
scenario = pd.read_excel("Scenario.xlsx")
services = pd.read_excel("Services.xlsx")
sites = pd.read_excel("Sites.xlsx")
```

```
In [3]: # dictionnaire pour renommer les colonnes et corriger les noms de départements
dict_rename = {"Site": "CodeInsee", "Compte": "AccountKey", "Année": "Annee", "Scenario": "S",
               "Service": "DepartmentGroupKey"}
dict_replace = {"10": "Aube", "11": "Aude", "13": "Bouches-du-Rhône"}
```

In [4]: *# Pour chaque data, changer les colonnes si possible*

```
budget.rename(columns=dict_rename, inplace=True)

comptes.rename(columns=dict_rename, inplace=True)

conso2014.rename(columns=dict_rename, inplace=True)

conso2015.rename(columns=dict_rename, inplace=True)

conso2016.rename(columns=dict_rename, inplace=True)

conso2017.rename(columns=dict_rename, inplace=True)
```

On remarque que certains codes pastaux ont quatre chiffres. Après vérification, ce sont les codes postaux qui commencent par zero. le fait de les enregistrer comme "int" agis sur ces chiffres. On corrige dans ce cas </blocquote>

```
In [5]: budget["CodeInsee"] = budget["CodeInsee"].astype(str)
budget["CodeInsee"] = budget["CodeInsee"].apply(lambda x: "0" + x if len(x) == 4 else x)
```

```
In [6]: budget.sample(10)
```

```
Out[6]:
```

	ScenarioKey	CodeInsee	DepartmentGroupKey	AccountKey	Date	Montant	
	586	2	67482	1	73	01/02/2016	5000
	1650	2	44109	6	80	01/05/2016	7500
	3572	2	78358	6	73	01/09/2016	2200
	874	2	06088	2	60	01/03/2016	101000
	2380	2	78646	1	66	01/06/2016	4800
	3832	2	67482	6	61	01/10/2016	26000
	1134	2	78358	6	52	01/03/2016	55000
	167	2	06088	6	81	01/01/2016	2800
	3059	2	75056	1	77	01/08/2016	4800
	3706	2	06088	2	73	01/10/2016	1100

Vérifions les données manquantes et les doublons </blocquote>

```
In [7]: manquant = budget.isnull().sum()
doublons = budget.duplicated().sum()

print(manquant, "\n" + "-----", "\n", doublons)
```

```
ScenarioKey      0
CodeInsee        0
DepartmentGroupKey 0
AccountKey       0
Date             0
Montant          0
dtype: int64
-----
2
```

```
In [8]: budget.drop_duplicates(inplace=True)
budget.duplicated().sum()
```

Out[8]: 0

```
In [9]: budget.describe()
```

Out[9]:

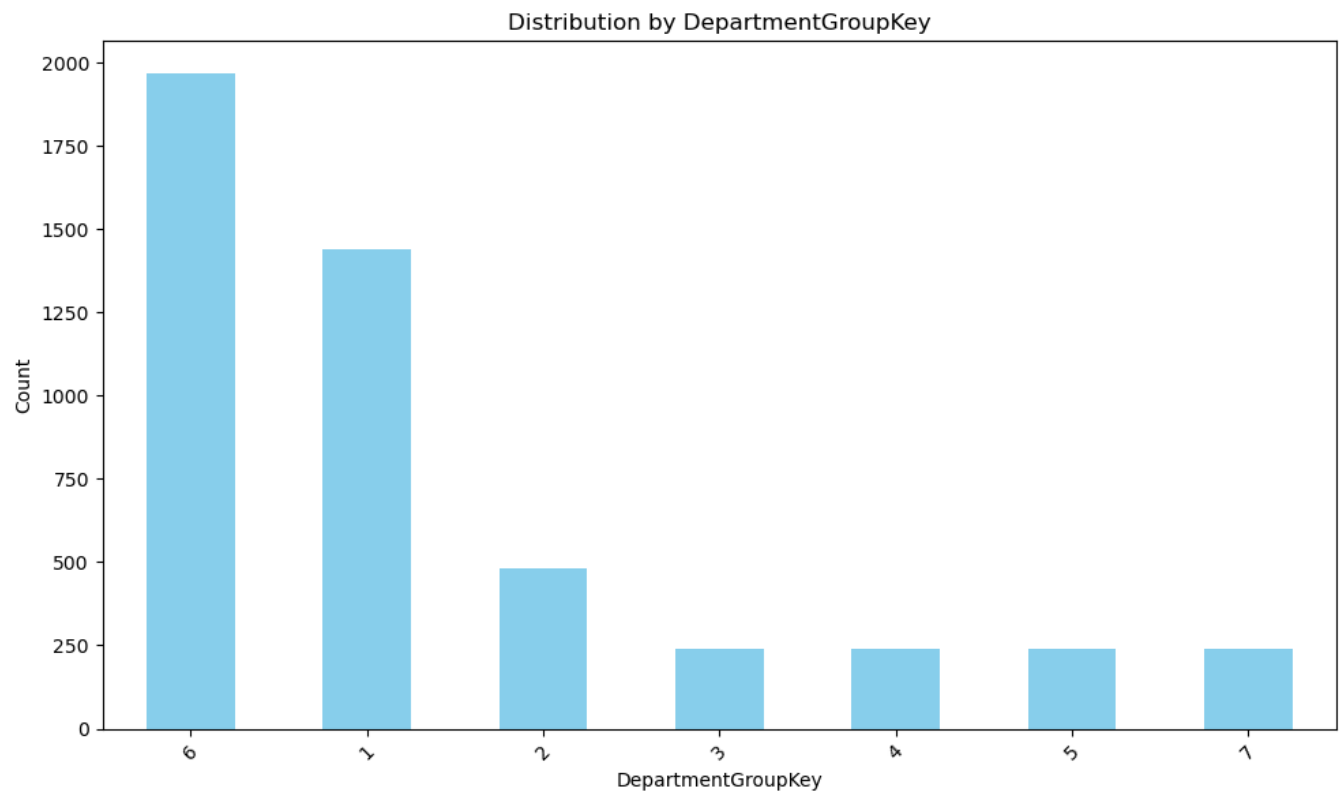
	ScenarioKey	DepartmentGroupKey	AccountKey	Montant
count	4844.0	4844.000000	4844.000000	4.844000e+03
mean	2.0	3.871594	72.959744	8.746448e+04
std	0.0	2.284988	9.935027	5.098863e+05
min	2.0	1.000000	52.000000	-1.600000e+04
25%	2.0	1.000000	65.000000	1.000000e+03
50%	2.0	5.000000	74.000000	2.800000e+03
75%	2.0	6.000000	81.000000	7.500000e+03
max	2.0	7.000000	101.000000	8.917000e+06

```
In [10]: #
departmentgroup_distribution = budget['DepartmentGroupKey'].value_counts()
```

```
In [11]: # Function to plot distribution
def plot_distribution(data, title, xlabel, ylabel, kind="bar"):
    ax = data.plot(kind=kind, figsize=(10, 6), color='skyblue')
    ax.set_title(title)
    ax.set_xlabel(xlabel)
    ax.set_ylabel(ylabel)
    plt.xticks(rotation=45)
    plt.tight_layout()
    plt.show()
    plt.savefig("Distri_by_Department")

# Plot distributions

plot_distribution(departmentgroup_distribution, "Distribution by DepartmentGroupKey", "Departm
```



<Figure size 640x480 with 0 Axes>

```
In [12]: # Conversion de 'Date' en datetime format
budget['Date'] = pd.to_datetime(budget['Date'], format='%d/%m/%Y')

# Extraction des mois et années
budget['Year'] = budget['Date'].dt.year
budget['Month'] = budget['Date'].dt.month

# Grouper par année et mois
time_series = budget.groupby(['Year', 'Month'])['Montant'].sum().reset_index()

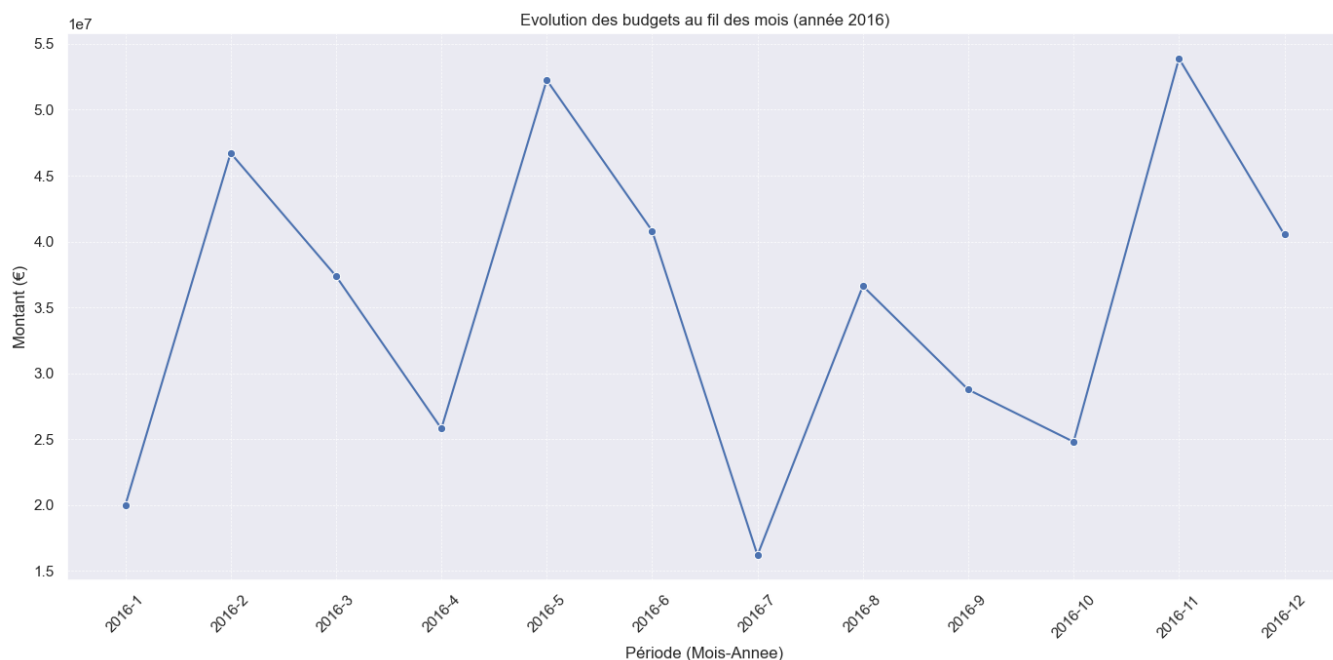
#
time_series.head()
```

```
Out[12]:
```

	Year	Month	Montant
0	2016	1	19968750
1	2016	2	46714500
2	2016	3	37373500
3	2016	4	25796300
4	2016	5	52255300

```
In [13]: # theme Seaborn par défaut
sns.set_theme()

# Plotting the time series of expenses using Seaborn
plt.figure(figsize=(14, 7))
sns.lineplot(data=time_series, x=time_series['Year'].astype(str) + '-' + time_series['Month'])
plt.title('Evolution des budgets au fil des mois (année 2016)')
plt.xlabel('Période (Mois-Annee)')
plt.ylabel('Montant (€)')
plt.xticks(rotation=45)
plt.grid(True, which='both', linestyle='--', linewidth=0.5)
plt.tight_layout()
plt.show()
plt.savefig("evolution_budget")
```



<Figure size 640x480 with 0 Axes>

```
In [14]: # Conversion de 'DepartmentGroupKey'
budget['DepartmentGroupKey'] = budget['DepartmentGroupKey'].astype(str)
services['DepartmentGroupKey'] = services['DepartmentGroupKey'].astype(str)

# jointure des dataframes on 'DepartmentGroupKey'
budget_services = pd.merge(budget, services, on='DepartmentGroupKey', how='left')

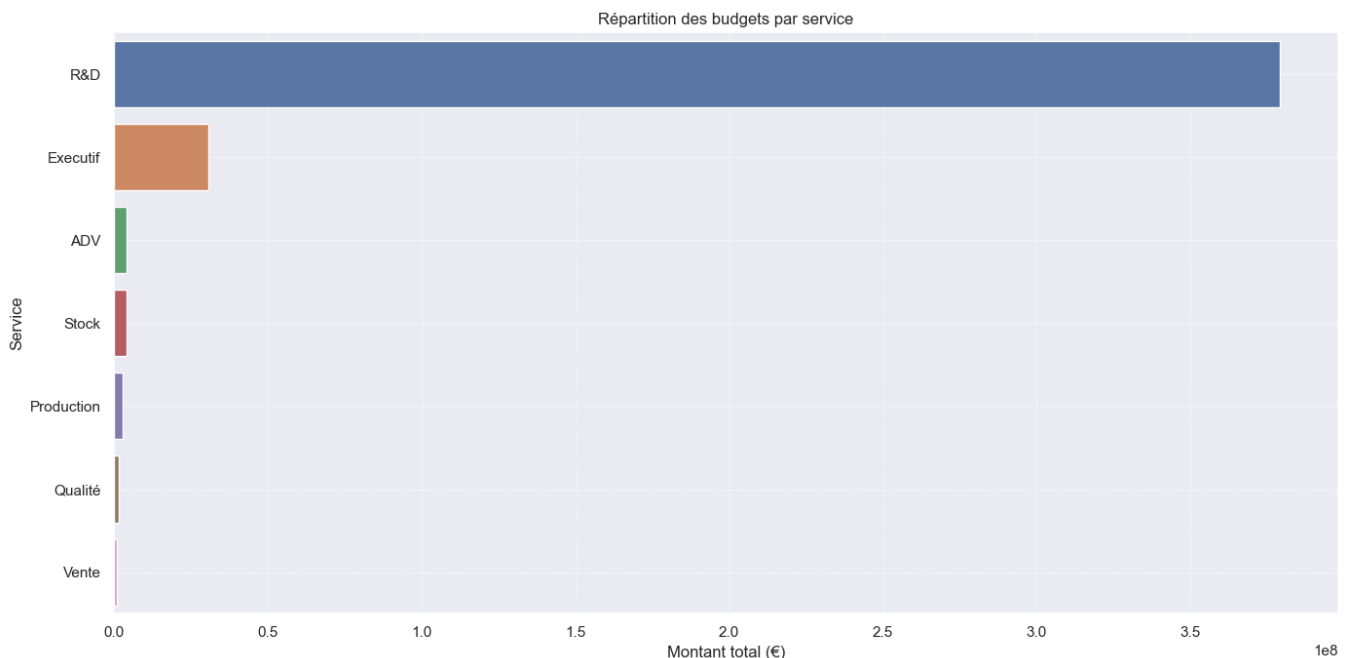
# affichage
budget_services.head()
```

```
Out[14]:
```

	ScenarioKey	CodeInsee	DepartmentGroupKey	AccountKey	Date	Montant	Year	Month	Service
0	2	44109	1	62	2016-01-01	14000	2016	1	Executif
1	2	44109	1	65	2016-01-01	3750	2016	1	Executif
2	2	44109	1	66	2016-01-01	5500	2016	1	Executif
3	2	44109	1	67	2016-01-01	2800	2016	1	Executif
4	2	44109	1	68	2016-01-01	2000	2016	1	Executif

```
In [15]: # Regrouper par service et obtenir La somme des "Montant" pour chaque service
grouped_service = budget_services.groupby('Service')['Montant'].sum().sort_values(ascending=False)

# Créer un diagramme à barres à l'aide de Seaborn
plt.figure(figsize=(14, 7))
sns.barplot(data=grouped_service, x='Montant', y='Service')
plt.title('Répartition des budgets par service')
plt.xlabel('Montant total (€)')
plt.ylabel('Service')
plt.grid(True, which='both', linestyle='--', linewidth=0.5)
plt.tight_layout()
plt.show()
plt.savefig("budget_par_services")
```



<Figure size 640x480 with 0 Axes>

```
In [16]: all_conso = pd.concat([conso2014, conso2015, conso2016, conso2017], ignore_index=True)
all_conso.sample(10)
all_conso.to_csv("all_conso.csv")
```

```
In [17]: data = pd.read_csv('all_conso.csv')
data.head()
```

Out[17]:

	Unnamed: 0	ScenarioKey	CodeInsee	DepartmentGroupKey	AccountKey	Annee	1	2	3	4
0	0	1	6088	1	60	2014	74195	71273	69758	87116
1	1	1	6088	1	61	2014	6573	7930	7333	8579
2	2	1	6088	1	62	2014	5548	5243	5159	7736
3	3	1	6088	1	65	2014	957	963	907	1328
4	4	1	6088	1	66	2014	871	876	825	1206

In [18]:

```
data.drop("Unnamed: 0", axis=1 , inplace=True)
# Afficher les premières lignes pour avoir un aperçu

data["CodeInsee"] = data["CodeInsee"].astype(str)
data["CodeInsee"] = data["CodeInsee"].apply(lambda x: "0" + x if len(x) == 4 else x).astype(str)

data.head()
```

Out[18]:

	ScenarioKey	CodeInsee	DepartmentGroupKey	AccountKey	Annee	1	2	3	4	5
0	1	06088	1	60	2014	74195	71273	69758	87116	74195 10
1	1	06088	1	61	2014	6573	7930	7333	8579	6573 1
2	1	06088	1	62	2014	5548	5243	5159	7736	5548
3	1	06088	1	65	2014	957	963	907	1328	957
4	1	06088	1	66	2014	871	876	825	1206	871

In [19]:

```
# Remplacer les virgules par des points et convertir en float
for month in range(1, 13):
    data[str(month)] = data[str(month)].str.replace(',', '.').astype(float)

# Vérifier les changements en affichant à nouveau les premières lignes
data.head()
```

Out[19]:

	ScenarioKey	CodeInsee	DepartmentGroupKey	AccountKey	Annee	1	2	3	4
0	1	06088	1	60	2014	74195.0	71273.0	69758.0	87116.0 74195
1	1	06088	1	61	2014	6573.0	7930.0	7333.0	8579.0 6573
2	1	06088	1	62	2014	5548.0	5243.0	5159.0	7736.0 5548
3	1	06088	1	65	2014	957.0	963.0	907.0	1328.0 957
4	1	06088	1	66	2014	871.0	876.0	825.0	1206.0 871

In [20]:

```
# Somme de la consommation pour chaque année
annual_consumption = data.groupby('Annee').sum().iloc[:, 5:17].sum(axis=1)

# Affichage de la consommation annuelle
annual_consumption
```


C:\Users\brune\AppData\Local\Temp\ipykernel\_19184\1625472053.py:2: FutureWarning: The default value of numeric\_only in DataFrameGroupBy.sum is deprecated. In a future version, numeric\_only will default to False. Either specify numeric\_only or select only columns which should be valid for the function.

```
annual_consumption = data.groupby('Annee').sum().iloc[:, 5:17].sum(axis=1)
```

Out[20]:

```
Annee
2014    1.423115e+09
2015    1.256621e+09
2016    1.427663e+09
2017    1.546113e+09
dtype: float64
```

```
In [21]: # Créer la visualisation avec seaborn
plt.figure(figsize=(10, 6))
sns.lineplot(x=annual_consumption.index, y=annual_consumption, marker='o', color='blue')
plt.title("Évolution de la consommation annuelle")
plt.xlabel("Année")
plt.ylabel("Consommation totale")
plt.tight_layout()
plt.show()
plt.savefig("conso_par_an")
```



<Figure size 640x480 with 0 Axes>

```
In [22]: # Grouper par année et sommer les consommations pour chaque mois
monthly_consumption = data.groupby('Annee').sum().iloc[:, 3:16]

# Afficher les premières lignes pour vérifier
monthly_consumption.head()
```

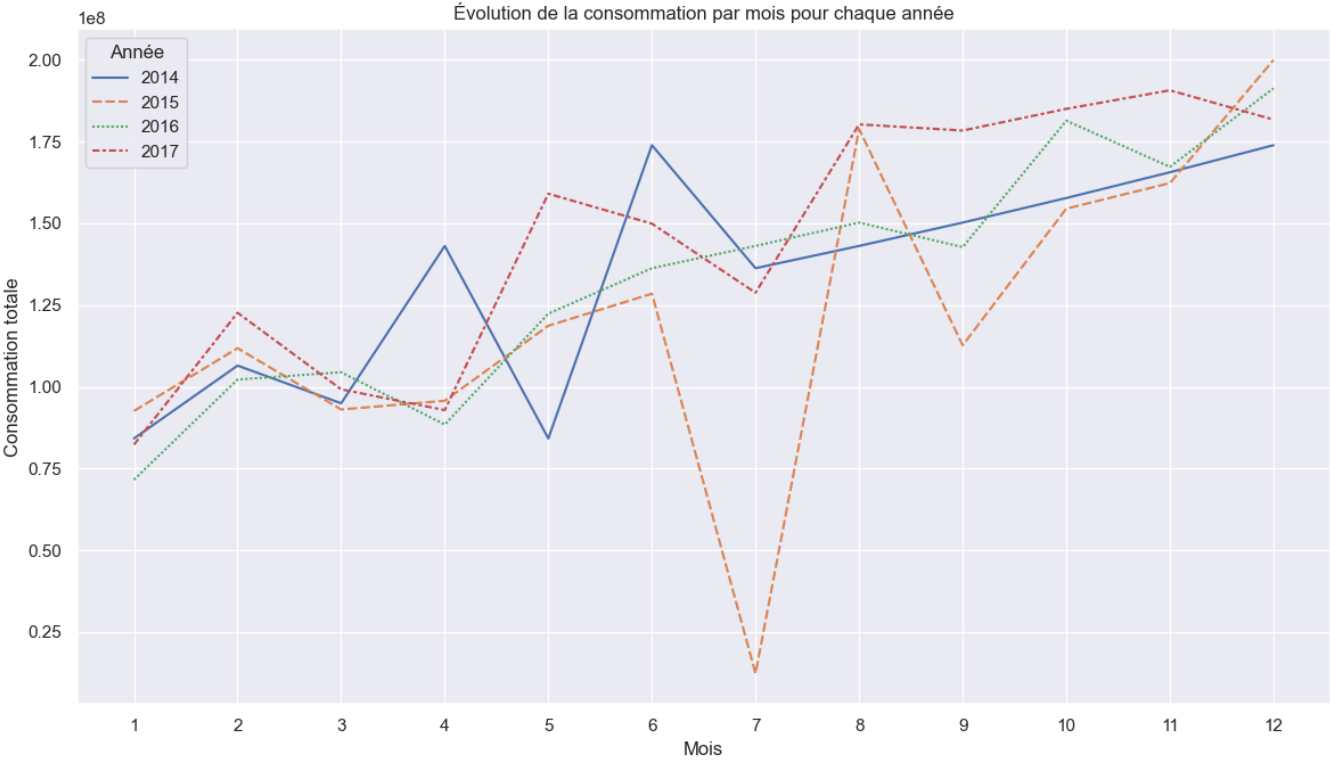
C:\Users\brune\AppData\Local\Temp\ipykernel\_19184\1073551443.py:2: FutureWarning: The default value of numeric\_only in DataFrameGroupBy.sum is deprecated. In a future version, numeric\_only will default to False. Either specify numeric\_only or select only columns which should be valid for the function.

```
monthly_consumption = data.groupby('Annee').sum().iloc[:, 3:16]
```

Out[22]:

	1	2	3	4	5	6	7	
Annee								
2014	8.417750e+07	1.064754e+08	9.494336e+07	1.430944e+08	8.417750e+07	1.739322e+08	1.362804e+08	1.
2015	9.259525e+07	1.117992e+08	9.304450e+07	9.572640e+07	1.186659e+08	1.284930e+08	1.226524e+07	1.
2016	7.155088e+07	1.022164e+08	1.044377e+08	8.843296e+07	1.223742e+08	1.362804e+08	1.430944e+08	1.
2017	8.228351e+07	1.226597e+08	9.921582e+07	9.285461e+07	1.590865e+08	1.499085e+08	1.287850e+08	1.

```
In [23]: # Tracer la visualisation de la consommation par mois pour chaque année
plt.figure(figsize=(12, 7))
sns.lineplot(data=monthly_consumption.T)
plt.title("Évolution de la consommation par mois pour chaque année")
plt.xlabel("Mois")
plt.ylabel("Consommation totale")
plt.legend(title='Année')
plt.tight_layout()
plt.show()
plt.savefig("conso_par_an_par_mois")
```



<Figure size 640x480 with 0 Axes>

```
In [24]: data.iloc[:, 4:17]
```

Out[24]:

	Annee	1	2	3	4	5	6	7	
0	2014	74195.0000	71273.000	69758.000	87116.0000	74195.000	105890.000	82968.000	871
1	2014	6573.0000	7930.000	7333.000	8579.0000	6573.000	10428.000	8171.000	85
2	2014	5548.0000	5243.000	5159.000	7736.0000	5548.000	9404.000	7368.000	77
3	2014	957.0000	963.000	907.000	1328.0000	957.000	1614.000	1265.000	13
4	2014	871.0000	876.000	825.000	1206.0000	871.000	1466.000	1149.000	12
...	...	...	...	...	...	...	...	...	...
4167	2017	119780.8950	178835.328	146900.875	145935.7725	179277.813	168934.920	145130.265	2031
4168	2017	21209.7950	25229.952	20583.365	21088.0425	25671.789	24190.320	20782.440	290
4169	2017	227482.8225	1030916.736	-32953.030	118470.9015	1591765.461	1499932.665	1288578.375	18040
4170	2017	690245.9850	1039753.728	793761.100	605343.4380	1376382.150	1296976.065	1114220.205	15599
4171	2017	14733.8575	16647.552	13941.345	14836.4895	17990.973	16953.090	14564.340	203

4172 rows × 13 columns



```
In [25]: # Vérifier le type de données de la colonne DepartmentGroupKey dans les deux dataframes
data_type_data = data["DepartmentGroupKey"].dtype
data_type_services = services["DepartmentGroupKey"].dtype

data_type_data, data_type_services
```

```
Out[25]: (dtype('int64'), dtype('O'))
```

```
In [26]: services["DepartmentGroupKey"] = services["DepartmentGroupKey"].astype(int)

# Fusionner data et services sur DepartmentGroupKey
merged_data = pd.merge(data, services, on="DepartmentGroupKey", how="left")

# Regrouper par Service et sommer les consommations pour chaque mois
consumption_by_service = merged_data.groupby('Service').sum().iloc[:, 3:17].sum(axis=1)

# Afficher la consommation par service
consumption_by_service
```

C:\Users\brune\AppData\Local\Temp\ipykernel\_19184\4193213251.py:7: FutureWarning: The default value of numeric\_only in DataFrameGroupBy.sum is deprecated. In a future version, numeric\_only will default to False. Either specify numeric\_only or select only columns which should be valid for the function.


```
consumption_by_service = merged_data.groupby('Service').sum().iloc[:, 3:17].sum(axis=1)
```

```
Out[26]: Service
ADV          2.001121e+08
Executif     8.980124e+07
Production   7.139189e+06
Qualité      3.938523e+06
R&D          9.515590e+08
Stock        4.434074e+08
Vente        4.739721e+09
dtype: float64
```


```
In [27]: # Créer un effet d'explosion pour toutes les sections
explode = [0.1] * len(consumption_by_service)
text_properties = {'fontsize': 12}
wedges, texts, autotexts = plt.pie(consumption_by_service, autopct='%1.1f%%', startangle=140,
                                     explode=explode, textprops=text_properties)

# Diagramme en secteur avec l'effet explode
plt.figure(figsize=(7, 10))
plt.pie(consumption_by_service, labels=consumption_by_service.index, autopct='%1.1f%%', startangle=140,
        explode=explode, textprops=text_properties)
plt.title("Répartition de la consommation par service (avec explosion)")
plt.legend(wedges, consumption_by_service.index, title="Services", loc="best")
plt.show()
plt.savefig("conso_service_diag_anneau")

# Diagramme en anneau pour la consommation par service avec une légende
plt.figure(figsize=(7, 10))
wedges, texts, autotexts = plt.pie(consumption_by_service, autopct='%1.1f%%', startangle=140,
                                     explode=explode, textprops=text_properties)
plt.title("Répartition de la consommation par service")
plt.legend(wedges, consumption_by_service.index, title="Services", loc="best")
plt.setp(autotexts, size=10, weight="bold")
plt.show()
plt.savefig("conso_service_diag_secteur")
```




Répartition de la consommation par service (avec explosion)



<Figure size 640x480 with 0 Axes>

## Répartition de la consommation par service



<Figure size 640x480 with 0 Axes>

```
In [28]: # Fusionner les dataframes data et comptes pour associer AccountKey à Poste
merged_data_poste = pd.merge(data, comptes, left_on="AccountKey", right_on="AccountKey", how='inner')

# Regrouper par Poste et sommer les consommations pour chaque mois
consumption_by_poste = merged_data_poste.groupby('Poste').sum().iloc[:, 5:17].sum(axis=1)

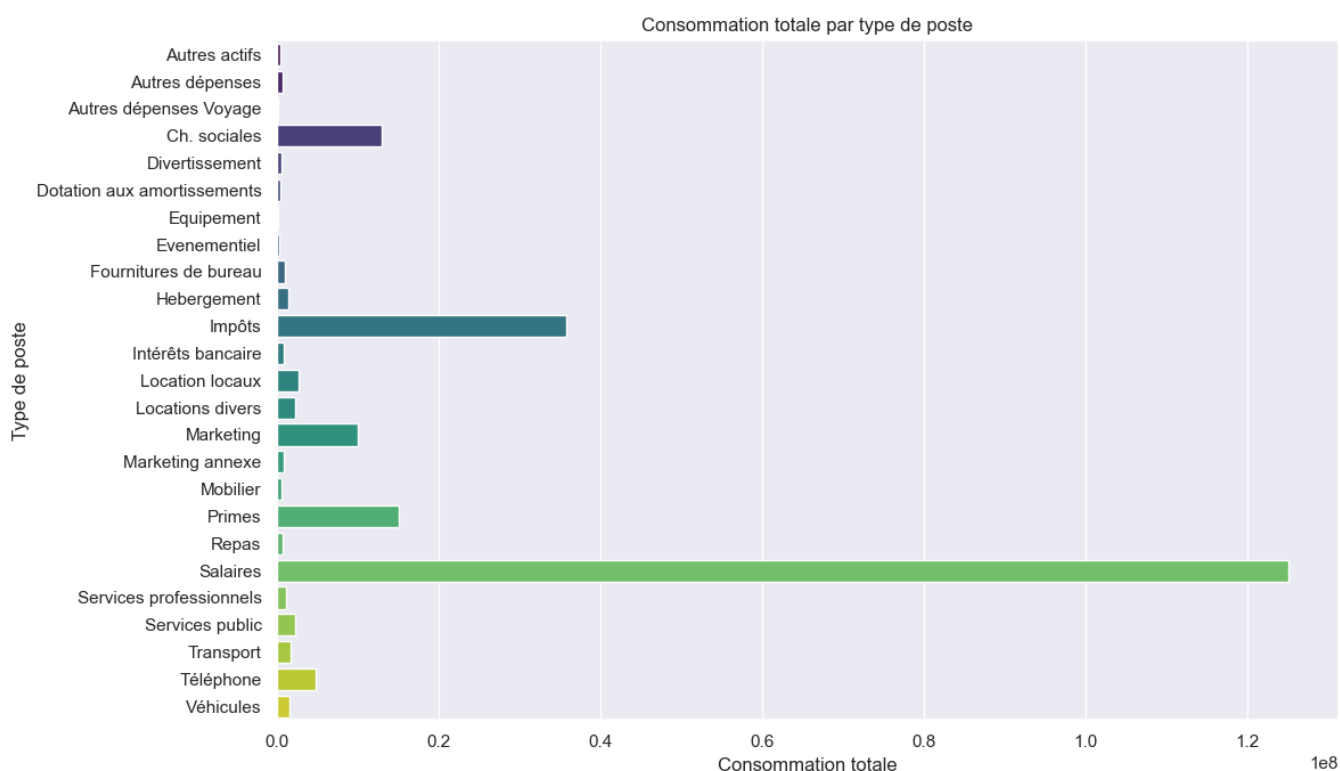
# Afficher la consommation par poste
consumption_by_poste
```

C:\Users\brune\AppData\Local\Temp\ipykernel\_19184\2204827171.py:5: FutureWarning: The default value of numeric\_only in DataFrameGroupBy.sum is deprecated. In a future version, numeric\_only will default to False. Either specify numeric\_only or select only columns which should be valid for the function.

```
consumption_by_poste = merged_data_poste.groupby('Poste').sum().iloc[:, 5:17].sum(axis=1)
```

```
Out[28]: Poste
Autres actifs 5.141042e+05
Autres dépenses 7.402522e+05
Autres dépenses Voyage 1.722141e+05
Ch. sociales 1.294906e+07
Divertissement 5.745881e+05
Dotation aux amortissements 5.174362e+05
Equipement 1.797428e+05
Evenementiel 2.854003e+05
Fournitures de bureau 1.092064e+06
Hebergement 1.516300e+06
Impôts 3.574340e+07
Intérêts bancaire 9.563583e+05
Location locaux 2.674581e+06
Locations divers 2.271543e+06
Marketing 1.006900e+07
Marketing annexe 9.545380e+05
Mobilier 5.894804e+05
Primes 1.506160e+07
Repas 7.737750e+05
Salaires 1.249898e+08
Services professionnels 1.197107e+06
Services public 2.277650e+06
Transport 1.684231e+06
Téléphone 4.880293e+06
Véhicules 1.634831e+06
dtype: float64
```

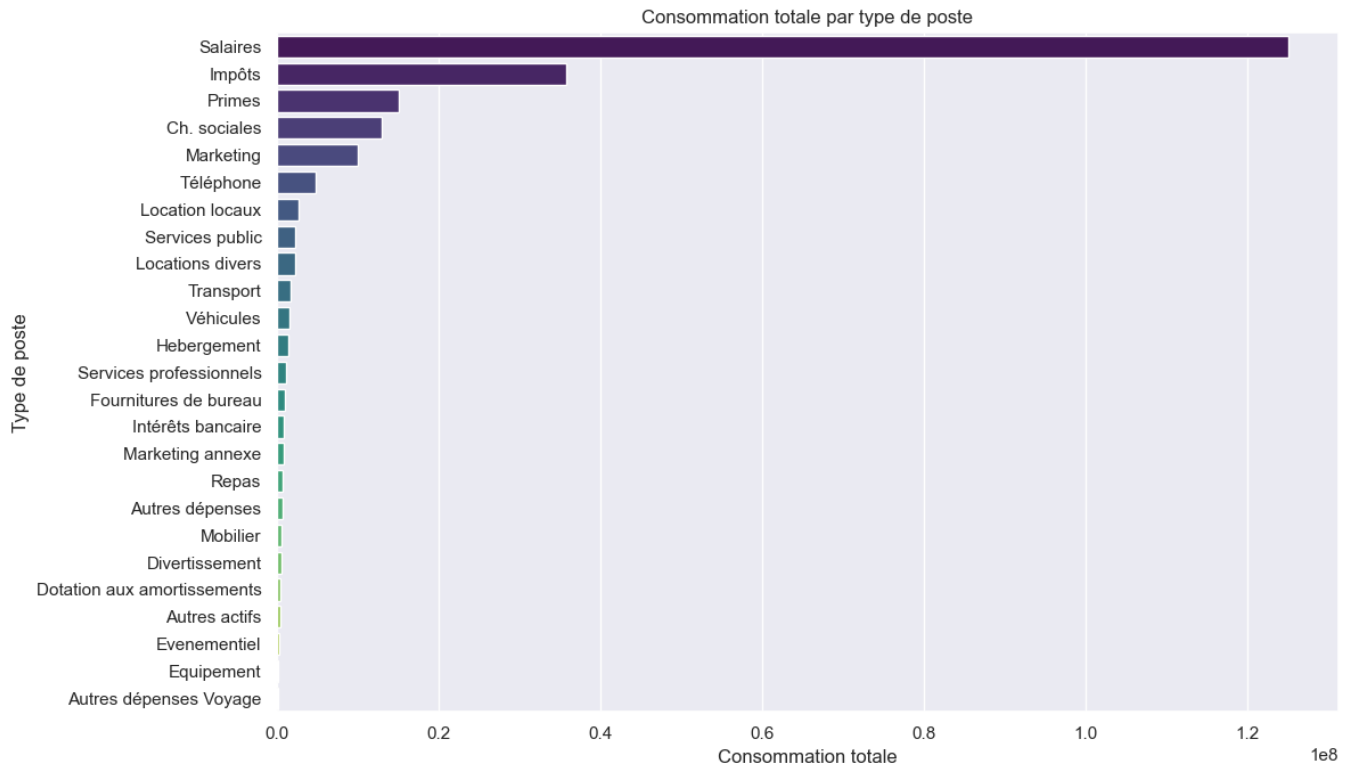
```
In [29]: # Trier les valeurs par consommation
consumption_by_poste = consumption_by_poste
# Diagramme à barres horizontales
plt.figure(figsize=(12, 7))
sns.barplot(x=consumption_by_poste.values, y=consumption_by_poste.index, palette="viridis")
plt.title("Consommation totale par type de poste")
plt.xlabel("Consommation totale")
plt.ylabel("Type de poste")
plt.tight_layout()
plt.show()
plt.savefig("conso_poste")
```



<Figure size 640x480 with 0 Axes>

```
In [30]: # Trier les valeurs par consommation
sorted_consumption_by_poste = consumption_by_poste.sort_values(ascending=False)

# Diagramme à barres horizontales
plt.figure(figsize=(12, 7))
sns.barplot(x=sorted_consumption_by_poste.values, y=sorted_consumption_by_poste.index, palette=
plt.title("Consommation totale par type de poste")
plt.xlabel("Consommation totale")
plt.ylabel("Type de poste")
plt.tight_layout()
plt.show()
plt.savefig("conso_poste_trie")
```



<Figure size 640x480 with 0 Axes>

```

In [31]: import plotly.graph_objects as go
import kaleido
#!pip install kaleido

sites["CodeInsee"] = sites["CodeInsee"].astype(int)

data["CodeInsee"] = data["CodeInsee"].astype(int)

# Calculer la consommation totale en 2017
merged_data_departement = pd.merge(data, sites[['CodeInsee', 'Departement']], on="CodeInsee",
total_conso_2017 = merged_data_departement[merged_data_departement["Annee"] == 2017].iloc[:, 1]

# Créer la jauge
fig = go.Figure(go.Indicator(
    mode = "gauge+number",
    value = total_conso_2017,
    domain = {'x': [0, 1], 'y': [0, 1]},
    title = {'text': "Consommation totale en 2017"},
    gauge = {
        'axis': {'range': [None, 1.2 * total_conso_2017]},
        'steps': [
            {'range': [0, 0.6 * total_conso_2017], 'color': "lightgray"},
            {'range': [0.6 * total_conso_2017, 0.9 * total_conso_2017], 'color': "gray"},
        ],
        'threshold': {
            'line': {'color': "red", 'width': 4},
            'thickness': 0.75,
            'value': total_conso_2017}}))

fig.show()
#fig.write_image("conso_jauge.png")

```

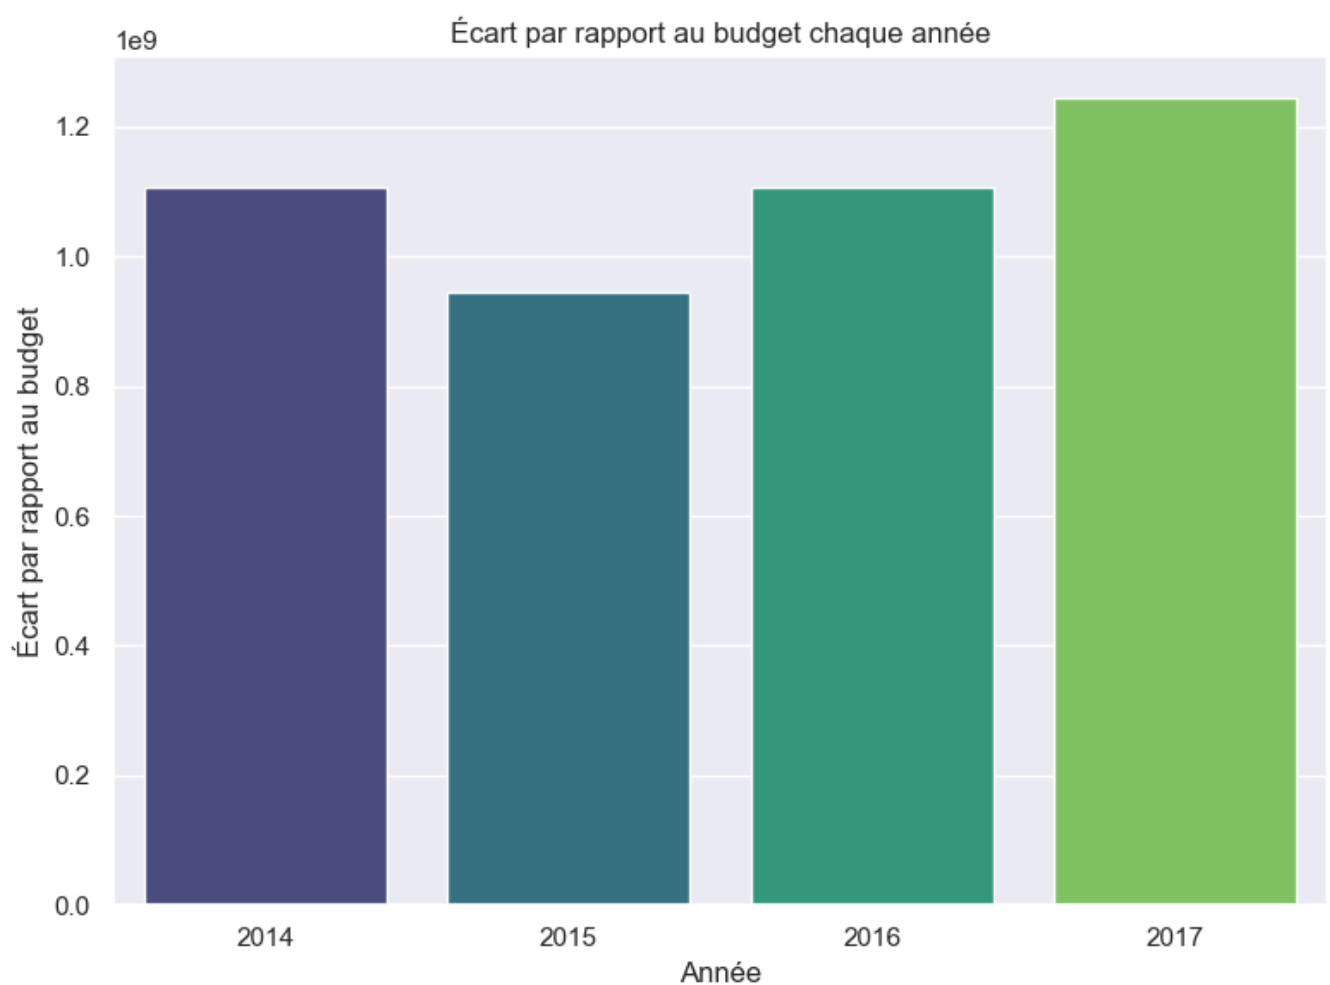
```
In [32]: # Calculer la consommation totale pour chaque année dans Le dataframe data
consumption_per_year = data.groupby('Année').sum().iloc[:, 5:17].sum(axis=1)

# Calculer Le budget total pour chaque année dans Le dataframe budget (en considérant que Le l
total_budget = budget['Montant'].sum()

# Calculer L'écart entre La consommation et Le budget pour chaque année
budget_difference = consumption_per_year - total_budget

# Afficher L'écart par rapport au budget pour chaque année
#budget_difference
```

```
In [33]: # Diagramme à barres pour visualiser L'écart par rapport au budget chaque année
plt.figure(figsize=(8, 6))
sns.barplot(x=budget_difference.index, y=budget_difference.values, palette="viridis")
plt.title("Écart par rapport au budget chaque année")
plt.xlabel("Année")
plt.ylabel("Écart par rapport au budget")
plt.tight_layout()
plt.show()
```



```
In [34]: # Modifier la colonne CodeInsee du dataframe sites
sites["CodeInsee"] = sites["CodeInsee"].astype(str)
sites["CodeInsee"] = sites["CodeInsee"].apply(lambda x: "0" + x if len(x) == 4 else x)

# Afficher Les premières lignes pour vérifier Les modifications
sites.sample(10)
```

Out[34]:

	CodeInsee	Commune	Departement	Region
531	34003	Agde	Hérault	Occitanie
751	66037	Canet-en-Roussillon	Pyrénées-Orientales	Occitanie
374	10033	Bar-sur-Aube	10	Grand Est
14	77284	Meaux	Seine-et-Marne	Ile de France
691	57618	Saint-Louis	Moselle	Grand Est
137	93063	Romainville	Seine-Saint-Denis	Ile de France
716	61006	Argentan	Orne	Normandie
842	76447	Montivilliers	Seine-Maritime	Normandie
367	08409	Sedan	Ardennes	Grand Est
700	58102	Donzy	Nièvre Bourgogne-Franche-Comté	

In [35]:

```
sites["Departement"] = sites["Departement"].replace(dict_replace)
sites.Departement.unique()
```

Out[35]:

```
array(['Paris', 'Seine-et-Marne', 'Yvelines', 'Essone', 'Hauts-de-Seine',
       'Seine-Saint-Denis', 'Val-de-Marne', "Val d'oise", 'Nord',
       'Pas-de-Calais', 'Alpes-de-Haute-Provence', 'Hautes-Alpes',
       'Alpes-Maritimes', 13, 'Var', 'Vaucluse', 'Ain', 'Aisne', 'Allier',
       'Ardèche', 'Ardennes', 'Ariège', 10, 11, 12, 'Calvados', 'Cantal',
       'Charente', 'Charente-Maritime', 'Cher', 'Corrèze', "Côte-d'Or",
       "Côtes-d'Armor", 'Creuse', 'Dordogne', 'Doubs', 'Drôme', 'Eure',
       'Eure-et-Loir', 'Finistère', 'Gard', 'Haute-Garonne', 'Gers',
       'Hérault', 'Ille-et-Vilaine', 'Indre', 'Indre-et-Loire', 'Isère',
       'Jura', 'Landes', 'Loir-et-Cher', 'Loire', 'Haute-Loire',
       'Loire-Atlantique', 'Loiret', 'Lot', 'Lot-et-Garonne', 'Lozère',
       'Maine-et-Loire', 'Manche', 'Haute-Marne', 'Mayenne',
       'Meurthe-et-Moselle', 'Meuse', 'Morbihan', 'Moselle', 'Nièvre',
       'Oise', 'Orne', 'Puy-de-Dôme', 'Pyrénées-Atlantiques',
       'Hautes-Pyrénées', 'Pyrénées-Orientales', 'Bas-Rhin', 'Haut-Rhin',
       'Rhône', 'Haute-Saône', 'Saône-et-Loire', 'Sarthe', 'Savoie',
       'Haute-Savoie', 'Seine-Maritime', 'Deux-Sèvres', 'Somme', 'Tarn',
       'Tarn-et-Garonne', 'Vendée', 'Vienne', 'Haute-Vienne', 'Vosges',
       'Yonne', 'Territoire de Belfort'], dtype=object)
```

In [36]:

```
# Convertir la colonne CodeInsee du dataframe sites en int64
sites["CodeInsee"] = sites["CodeInsee"].astype(int)


data["CodeInsee"] = data["CodeInsee"].astype(int)

# Fusionner à nouveau les dataframes
merged_data_departement = pd.merge(data, sites[['CodeInsee', 'Departement']], on="CodeInsee",
                                     how="left")

# Regrouper par Departement et sommer les consommations pour chaque mois
consumption_by_departement = merged_data_departement.groupby('Departement').sum().iloc[:, 5:15]

# Diagramme à barres pour visualiser la consommation par département
plt.figure(figsize=(14, 10))
sns.barplot(y=consumption_by_departement.index, x=consumption_by_departement.values, palette="magma")
plt.title("Consommation totale par département")
plt.ylabel("Département")
plt.xlabel("Consommation totale")
plt.tight_layout()
plt.show()
```





```
In [37]: # Regrouper Les données par CodeInsee et sommer La consommation pour chaque mois
consumption_by_codeinsee = merged_data_departement.groupby('CodeInsee').sum().iloc[:, 5:17].sort_values(ascending=False)

# Convertir Le CodeInsee en string pour L'utiliser avec Plotly
consumption_by_codeinsee.index = consumption_by_codeinsee.index.astype(str)

# Vérifier Les premières entrées des données préparées
consumption_by_codeinsee.head()
```

C:\Users\brune\AppData\Local\Temp\ipykernel\_19184\2847228493.py:2: FutureWarning:

The default value of numeric\_only in DataFrameGroupBy.sum is deprecated. In a future version, numeric\_only will default to False. Either specify numeric\_only or select only columns which should be valid for the function.

```
Out[37]: CodeInsee
6088      1.376600e+09
44109     1.040910e+09
67482     6.293076e+08
69123     2.860163e+08
75056     5.462884e+08
dtype: float64
```

```
In [38]: #!/pip install bokeh
from bokeh.models import GeoJSONDataSource
from bokeh.plotting import figure, show, output_notebook
from bokeh.io import push_notebook
from bokeh.palettes import Viridis256
from bokeh.models import ColorBar, LinearColorMapper
from bokeh.layouts import column

# Charger à nouveau Le fichier geojson
with open("departements-version-simplifiee.geojson.txt", "r") as file:
    geojson_departements = json.load(file)
    min_val = consumption_by_codeinsee.min()
    max_val = consumption_by_codeinsee.max()
    color_mapper = LinearColorMapper(palette=Viridis256, low=min_val, high=max_val)

# Ajouter Les valeurs de consommation dans Les données GeoJSON
for feature in geojson_departements['features']:
    code = feature['properties']['code']
    if code in consumption_by_codeinsee:
        feature['properties']['consommation'] = consumption_by_codeinsee[code]
    else:
        feature['properties']['consommation'] = 0 # Si nous n'avons pas de données pour ce d

# Convertir Le dataframe de consommation mis à jour en source de données pour Bokeh
source = GeoJSONDataSource(geojson=json.dumps(geojson_departements))

# Créer La figure avec La propriété correcte pour définir La hauteur
p = figure(title="Consommation totale par département",
            height=600,
            width=900,
            tools="pan,reset,save,wheel_zoom,box_zoom")

# Ajouter Les polygones représentant Les départements
p.patches('xs', 'ys', source=source,
          fill_color={'field': 'consommation', 'transform': color_mapper},
          line_color='white', line_width=0.5)

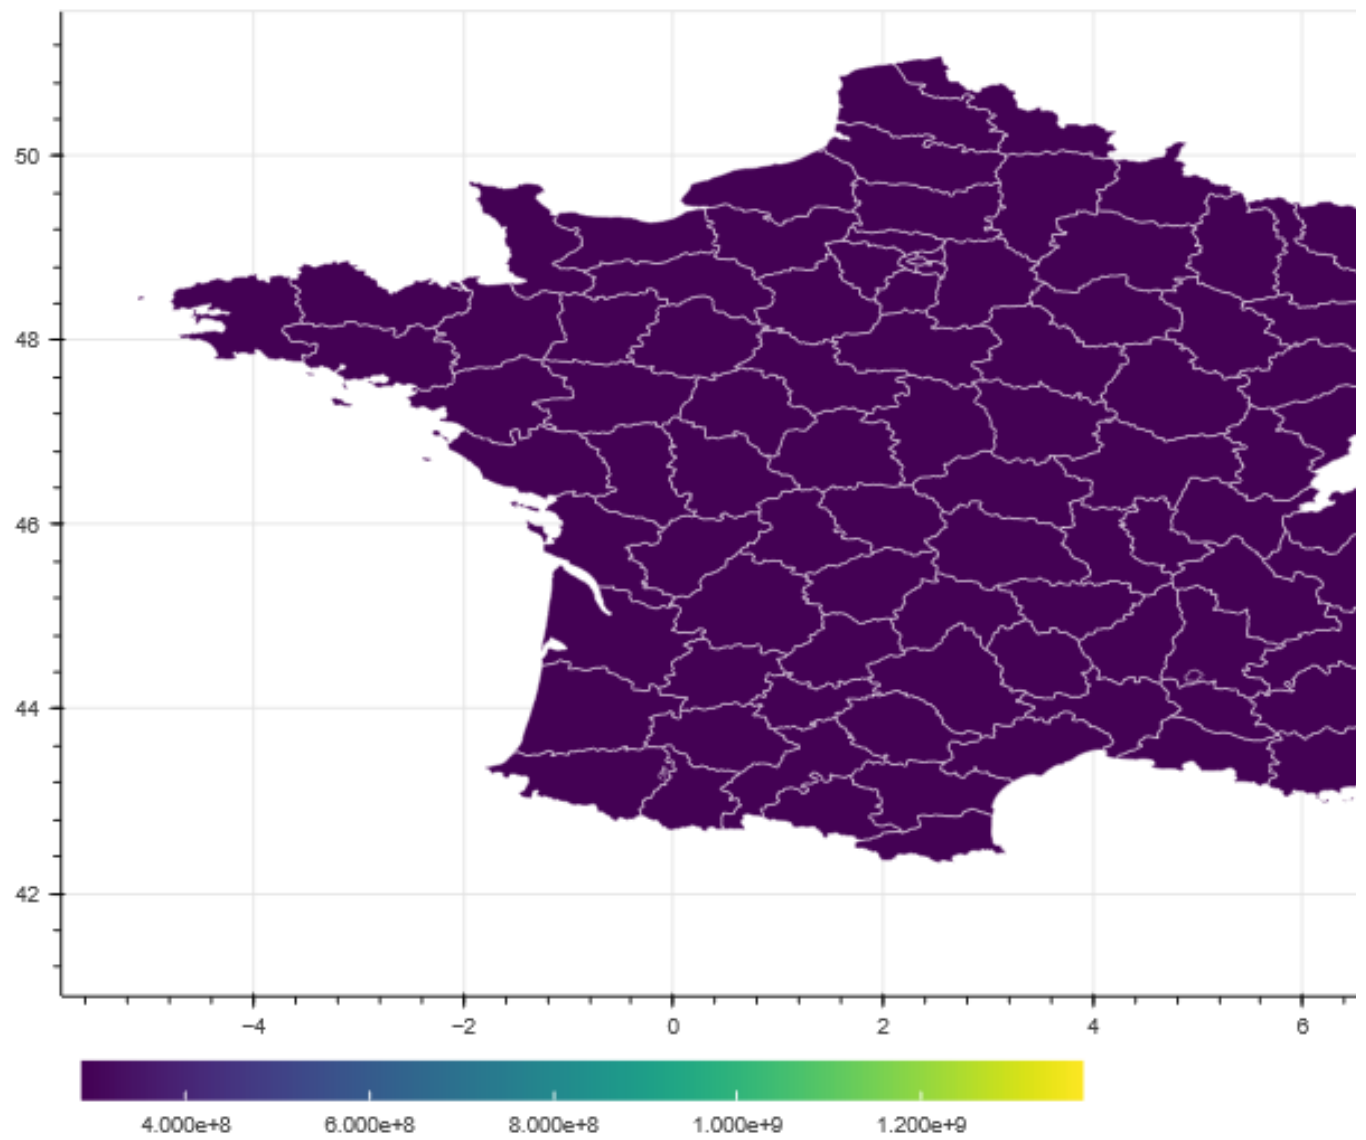
# Ajouter une barre de couleur
color_bar = ColorBar(color_mapper=color_mapper, label_standoff=8, width=500, height=20, locat:
p.add_layout(color_bar, 'below')

# Afficher La figure
output_notebook()
show(p, notebook_handle=True)
```



BokehJS 3.2.2 successfully loaded.

Consommation totale par département



Out[38]: <Bokeh Notebook handle for In[38]>

In [ ]: